

1차원 합성곱 신경망을 이용한 급성 심장사 예측

비스와바르단 레디 카르나1, 카르나 비슈누 바르다나 레디2
 1RV 공과대학 전자통신공학과, 벵갈루루, 인도
 2전자통신공학과, 아디티야 공과대학(A), 수람팔렘, 인도

기사 정보	추상적인
기사 이력:	급성 심정지(SCA)는 증상이나 경고 없이 발생하는 심각한 심장 질환입니다. SCA는 사망률이 매우 높기 때문에 발생률을 예측하는 것이 중요합니다. 현재 심실세동(VF) 발생 예측 방법은 환자를 장기간 모니터링해야 하므로 합병증을 유발할 수 있습니다. 머신러닝과 같은 새로운 기술은 여러 가지 이점을 제공하여 주목받고 있습니다. 그러나 기존 시스템 대부분은 수동 처리에 의존하기 때문에 환자 정보 전달에 비효율성이 발생할 수 있습니다. 또한, 기존 딥러닝 방법은 공개적으로 이용할 수 없는 대규모 데이터셋에 의존합니다. 본 연구에서는 원시 심전도(ECG) 신호에서 이산 푸리에 변환(DFT) 특징을 학습하는 1차원 합성곱 신경망 기반 딥러닝 방법을 제안합니다. 실험 결과, 제안된 방법은 SCA 발생 약 90분 전에 96%의 정확도로 SCA 발생을 예측할 수 있었습니다. 이러한 예측은 많은 생명을 구할 수 있습니다. 즉, 최적화된 딥러닝 모델은 장기간 신호 분석에서 수동 모델보다 우수한 성능을 보일 수 있습니다.
2023년 7월 31일 접수	
2023년 9월 29일 수정됨	
2023년 11월 7일 승인됨	
키워드:	
부정맥 위험 지표	
심전도	
머신러닝	
급성 심장사	
급성 심장사 예측	

이 논문은 CC BY-SA 라이선스에 따라 누구나 자유롭게 이용할 수 있습니다. 특히,



교신 저자:

비스와바르단 레디 카르나

인도 벵갈루루 마이소르 로드 RV 공과대학 전자통신공학과, 우편번호 560059 이메일: viswavardhank@rvce.edu.in

1. 서론

21세기 초부터 심전도(ECG)는 심혈관 질환 진단의 기초가 되어 왔습니다[1]. ECG 신호는 심장의 전기적 활동을 보여주므로 부정맥과 같은 다양한 심장 질환이나 이상을 진단하는 데 도움이 됩니다[2]. 이러한 이상을 감지하려면 장기간 모니터링이 필요하며, 이는 급성 심장사(SCD)로 이어질 수 있습니다. 더욱이 최근 코로나19 팬데믹으로 인해 급성 심정지(SCA)로 인한 사망률이 크게 증가했으며[3]–[5], 전 세계적으로 약 300만 명이 뚜렷한 증상 없이 SCD의 영향을 받을 것으로 추산됩니다[6]. 정확한 원인은 밝히지 않았지만, 심실세동(VF)이 SCD 사례의 20%를 차지하는 것으로 알려져 있습니다[7]. SCD는 심장이 신체 장기에 효율적으로 혈액을 공급하지 못하는 SCA로 인해 발생합니다. 이는 체내 산소량의 급격한 감소를 초래하고 몇 분 안에 의식 상실로 이어집니다[8]. 또한, 심정지(SCA)와 급성심장사(SCD) 사이의 시간 간격이 짧기 때문에 사망을 예방하기 위해서는 이 시간 내에 혈액 순환을 회복시키는 것이 매우 중요합니다. 최근 공공장소에서 시행되는 제세동기(PAD) 시술은 심정지 후 급성심장사 환자를 소생시키는 방법으로 많은 주목을 받고 있습니다. PAD가 널리 보급되고 있지만, 더 나은 접근법은 급성심장사의 발생을 감지하고 예방하여 심정지 발생 전에 응급 처치를 제공하는 것입니다.

이러한 경고 시스템을 개발하면 전문가들이 발병 몇 분 또는 몇 시간 전에 이를 감지하는 데 도움이 될 수 있습니다.

필요한 예방 조치를 취할 수 있습니다[9]. 기술 발전으로 디지털 장치를 통해 모니터링과 데이터 수집을 개선할 수 있는 새로운 방법이 가능해졌습니다 [10].

최근의 SCD 탐지 및 예측 연구에서는 ECG 신호를 사용하여 학습에 적합한 특징을 생성합니다. 머신러닝 모델[11]–[16]. 이러한 모델에는 서포트 벡터 머신(SVM)[17], [18], 선형 머신 등이 포함됩니다. 판별 분석(LDA), 심층 신경망(DNN)[19] 및 회전된 숲(RF)[20]. 이러한 특징들 데이터에 의존적인 경우가 많고, 분포 범위를 벗어난 신호가 주어지면 제대로 작동하지 않는 경우가 흔합니다. 이러한 문제를 해결하기 위해 최근 심장 질환 진단에 머신러닝이 활용되고 있는 만큼, 강력한 모델을 구축하는 것이 필수적입니다. 차이점을 수용할 수 있는.

머신러닝은 거의 모든 분야에서 활용도가 증가하고 있습니다. 이 기술은 모델을 생성하는 데 기반을 두고 있습니다. 환자의 심전도 또는 심박수 변동성(HRV) 신호를 기반으로 하는 새로운 특징을 사용하여 정확하게 진단합니다. 심장 돌연사(SCD) 발생 몇 분 전을 예측할 수 있습니다. 심전도(ECG) 신호는 사실상 표준으로 자리 잡았습니다. 심장 질환 진단을 위한 주요 특징을 파악하는 기술들은 환자의 생존율을 향상시키기 위해 입원 환자 치료에 필수적인 요소가 되었습니다. 예를 들어, Yadav 등은 SCA(급성 심정지)의 조기 발견을 위해 다음과 같은 방법을 제안했습니다. 랜덤 포레스트 분류기(RF) [9]. 본 연구는 MIMIC-III 데이터 보고서를 사용하여 수행되었으며, 여기에는 다음이 포함됩니다. 혈압, 체내 이온 수치(칼슘, 칼륨) 등 환자의 여러 특성뿐만 아니라 기타 요인들도 고려해야 합니다. 본 연구는 집중치료실(ICU) 관찰실의 특성을 분석하기 위해 RF(랜덤 포레스트)를 사용하여 최적화했습니다. 그리드 검색과 유전 알고리즘을 사용하여 모델의 하이퍼파라미터를 최적화하고, 연산자 아래 면적(AUC)을 달성을 합니다. AUC(곡선 면적) 값은 0.9787입니다.

심전도와 불규칙한 심장 박동은 문헌에서 조기 심정지(SCA)를 예측하는 데 사용되는 특징입니다. Murugappan 등 [11]은 심실세동(VF) 발생 5분 전 SCA를 예측하기 위해 ECG 신호에서 얻은 여러 매개변수를 보고했습니다. 이러한 특징에는 허스트 지수, 엔트로피, 최대 리아푸노프 지수가 포함되며, 이를 사용하여 서포트 벡터 머신(SVM), 신경 퍼지 분류기, 감산 퍼지 클러스터링의 세 가지 다른 방법을 학습시켰습니다. SVM 분류기를 사용한 연구에서는 MIT-보스턴 베스 이스라엘 병원(MIT-BIH) 데이터셋을 사용하여 100%의 정확도를 달성했습니다. 한편, Lai 등 [21]은 급성 심장 사(SCD)의 조기 발견을 예측하기 위해 다양한 부정맥 마커의 사용을 제안했습니다. 여기에는 JT_p/JT_e, TpTe/QT와 같은 재분극 신호가 포함됩니다.

QRS 파형 및 ECG 특성으로부터 직접 얻은 값과, TpTe/QRS 및 TpTe/(QT c QRS)와 같은 전도 기반 재분극 값은 QRS 파형 및 ECG 신호로부터 직접 계산되었습니다.

18명의 정상 환자와 28명의 SCD 환자로 구성된 데이터 세트를 사용하여 제안된 방법은 SCD 발생 30분 전에 SCD를 식별하여 RF를 통해 평균 99.49%의 정확도를 달성했습니다. Alfaras et al. [10]은 에코 상태 네트워크(ESN)를 분류기로 사용하여 ECG 리드를 이용한 부정맥 예측 시스템을 제안했습니다.

ECG 재샘플링, 필터링, 심장 박동 감지 및 특징 정규화를 포함한 다양한 전처리 단계를 적용하여 총 63개의 특징을 추출했습니다. MIT-BIH 데이터셋을 사용하여 ESN 양상들을 적용한 결과, 민감도 95.7%, 양성 예측값 75.1%를 달성했습니다. 18명의 데이터를 사용하여...

정상 환자 28명과 SCD 환자 28명을 대상으로 제안된 방법은 RF를 사용하여 99.49%의 정확도를 달성했습니다.

SCD가 발생하기 30분 전에 SCD를 식별합니다. Echo State Network(ESN)을 분류기로 사용하여 Alfaras et al. [10]

심전도 처리를 이용한 부정맥 예측기를 제안하였다. 다양한 전처리 기법이 사용되었습니다.

ECG 리샘플링, 필터링, 심장 박동 감지 및 특징 정규화를 포함하여 총 63개의 결과가 나왔습니다.

이 연구는 MIT-BIH 데이터셋을 사용하여 95.7%의 민감도와 75.1%의 양성 예측값을 보고했습니다.

ESN 코호트를 사용합니다.

Ebrahimzadeh et al. [22]은 로컬 시간 부분집합 특징 선택 기법의 새로운 방법을 제안했습니다.

본 연구는 급성 심장사(SCD) 발생 12분 전을 예측하는 최적화된 방법을 제시하고, 전자 장비의 성능을 개선하는 데에도 기여했습니다.

훈련 프로그램 합의 시 83%의 효과적인 자극 수용률을 확인하기 위한 다양한 통계 분석

다층 퍼셉트론(MLP) 분류기를 사용하여 특징을 추출합니다. Ebrahimzadeh et al.은 이전 연구를 이어가고 있습니다.

[7]에서 제안된 풀에서 합의 선택 전략을 만들어 SCD를 정확하게 예측하는 것이 제안되었습니다.

본 연구에서는 이전 연구에서 제안한 신체 부위별 신체 선택 과정을 이용하여 다음과 같은 내용을 제안합니다.

K-최근접이웃(KNN), SVM, MLP 모델들을 학습시키기 위해 특징들을 선택하였다. 이 계획을 평가하였다.

MIT-BIH 저장소에서 사용되었으며, SCD 발생 31분 전 분석에서 82.85%의 정확도를 달성했습니다.

Khazaeei et al. [23]은 비단조성을 기반으로 하는 SCD의 조기 발견을 위한 새로운 방법을 제안했습니다.

심박수 변동성의 패턴. 그들의 연구에서는 재귀적 분위수 분석과 증분적 분석을 기반으로 한 특징들을 사용했습니다.

차원 축소를 위해 변분 분석 방법을 사용하여 엔트로피를 추출했습니다.

의사결정 트리 분류기를 사용한 제안된 방법은 심장 돌연사(SCD) 발생 6분 전을 95%의 정확도로 감지할 수 있습니다.

시작. 마찬가지로 Sanchez et al. [24]은 ECG 신호의 웨이블릿 변환을 기반으로 하는 특징 집합을 제안했습니다.

그들의 연구에서는 동질성 지수, 웨이블릿 패킷 변환(WPT) 등의 방법을 사용했습니다.

신경망의 연결성을 보여주기 위해 비선형 측정을 사용합니다. 본 연구에서는 MIT-BIH를 활용합니다.

해당 시스템은 심장 돌연사 발생 20분 전에 95.8%의 정확도로 심장 돌연사를 감지할 수 있으며, 이를 평가하기 위해 데이터 세트를 사용했습니다.

또한, Acharya et al. [25]은 비단조성을 추출하여 SCD를 예측하는 새로운 특징을 제안했습니다.

심전도 신호의 비단조 변환(DWT)에서 나타나는 특징들. 이러한 특징에는 프렉탈 차원이 포함됩니다.

(FD), 세제 없는 변동 분석(DFA), 허스트 지수, 근사 엔트로피 및 상관 차원.

추출된 결과를 바탕으로 슈퍼리스트 방법을 사용하여 급성 심장사 지수(SCDI)를 생성했습니다.

SVM 분류기를 사용하면 4분 전에 SCD를 92.11%의 정확도로 예측할 수 있습니다.

주로 ECG 신호에 초점을 맞춘 다른 연구들과 달리, Fujita et al. [26]은 4분 HRV 신호 분석을 위한 여러 비선형 방법을 제안했습니다. 이러한 방법에는 Tsallis 엔트로피(TEnt), Renyi 엔트로피(REnt), Hjorth 매개변수(활동성, 이동성 및 복잡성), 그리고 웨이블릿 변환(DWT)의 에너지 특성이 포함됩니다. SVM 분류기를 사용한 이 제안된 방법은 SCD 발생 4분 전에 94.7%의 정확도를 달성했습니다.

딥러닝은 수작업으로 추출한 특징 추출 방식에서 많은 개선점을 보여주었습니다. 예를 들어, 권 등은 체온, 호흡률, 수축기 혈압, 심박수라는 네 가지 생체 징후만을 이용하여 병원에서 심장마비를 예측하는 심층 연구를 수행했습니다[27]. 제안된 모델은 순환 신경망(RNN)을 기반으로 하며 두 개의 임상 데이터셋으로 검증되었습니다. 제안된 시스템의 수신자 작동 특성 곡선(AUROC) 아래 면적은 0.85로, 머신러닝 기반의 다른 랜덤 포레스트(RF) 및 로지스틱 회귀 모델보다 우수한 성능을 보였습니다. 한편, 엘로라 등은 외래 환자의 심정지를 감지하는 딥러닝 모델을 개발했습니다[28]. 저자들은 5초 분량의 심전도 시퀀스를 사용하여 심장 리듬이 무맥성 리듬(PEA)인지 무맥성 리듬(PR)인지 판별하기 위해 합성곱 신경망(CNN)과 순환 신경망(RNN) 기반의 두 가지 모델을 분석했습니다. 두 모델은 RNN 모델의 경우 95.5%, CNN 모델의 경우 94.1%의 특이도로 93.5%의 정확도를 달성했습니다. 마찬가지로 Nguyen et al. [29]은 심전도, 충격 가능 리듬(SH) 및 충격 불가능 리듬을 이용한 SCA 초기 감지를 지원하는 CNN 모델과 결합된 충격 조정 시스템(SAA)을 제안했습니다. 제안된 방법은 CNN을 사용하여 신호에서 특징을 추출하고 이를 최적화 입력으로 사용합니다. 저자들은 5겹 교차 검증을 사용한 그리드 검색 알고리즘으로 테스트를 검증했으며 99.26%의 정확도, 99.44%의 특이도 및 97.07%의 민감도를 보고했습니다. Tone Carboni et al.

[30]은 심박수, 호흡수, 맥박수, 산소포화도, 동맥혈압, RR 간격의 표준편차 등 다양한 신체 매개변수를 이용하여 중환자실 환자의 심정지를 예측하기 위해 CNN과 장기 기억(LSTM)을 결합한 방법을 제안했습니다. CNN을 사용하여 신체의 고수준 정보를 추출하고 이를 LSTM 챠귀와 결합하여 신호의 시간 의존적 전류를 포착합니다. 제안된 방법은 심박수를 주요 요인으로 하여 다양한 신체 증상에 대해 0.61~0.83 범위의 F1 점수를 달성했습니다.

RF와 같은 머신러닝 모델 사용 시 흔히 발생하는 오탐을 줄이기 위해, 체온(BT), 호흡률(RR), 심박수(HR), 측정된 수축기 혈압 등 4가지 주요 매개변수를 사용하여 학습하는 딥러닝 모델을 제안하였다[31]. 제안된 방법은 24시간 이내 심정지 예측에서 AUROC 0.911로 다른 RF 및 LR 기반 모델보다 우수한 정확도를 보였다. 마찬가지로, Kim 등 [32]은 중환자실 환자 데이터(병력, 최근 수술, 현재 건강 상태, 활력 징후 등)를 기반으로 심정지 및 호흡 부전을 예측할 수 있는 인공지능 시스템을 개발하였다. 제안된 모델은 128개 유닛의 LSTM 레이어와 0.5 확률 출력 방식을 사용하였다. 이 모델은 1시간 이내 심정지 예측에서 AUC-ROC 0.886, 6시간 이내 호흡 부전 예측에서 AUC-ROC 0.869를 나타냈다.

기존 문헌을 살펴보면, 대부분의 연구는 심전도(ECG) 신호의 고차 선형 및 비선형 시간-주파수 특징을 수작업으로 추출하여 심정지를 예측하는 데 초점을 맞추고 있습니다. 이러한 특징에는 심박수 변동성과 같은 시간 영역 특징의 통계적 함수와 스펙트럼 분포와 같은 주파수 영역 특징이 포함됩니다. 또한, 이러한 연구들은 비교적 짧은 시간 동안의 급성 심장사(SCD) 발생 예측에 집중되어 있습니다. 이는 예측 시점을 앞당길 경우 특징 추출 과정이 복잡해져 확장성이 떨어지기 때문일 가능성이 높습니다. 반면, 딥러닝 접근법은 상당한 성능 향상을 보여주었지만, 방대한 양의 데이터를 학습해야 한다는 한계가 있습니다. 또한, 이러한 연구들은 주로 병원 밖 환자를 대상으로 하며 체온, 산소 포화도 및 기타 생리적 특징과 같은 다른 특징들을 활용합니다. 본 연구에서는 이러한 기존 연구들의 한계를 극복하기 위해, 원시 ECG 신호만을 사용하여 딥러닝 기법으로 특징 추출 과정을 자동화합니다. 이를 위해 ECG 신호의 이산 푸리에 변환(DFT)을 이용하여 1차원 합성곱 신경망(CNN)을 학습시킵니다. CNN 네트워크 학습에 이산 푸리에 변환(DFT) 특징을 활용함으로써 데이터 효율성을 높이면서도 우수한 성능을 유지할 수 있었습니다. 결과 섹션에서 볼 수 있듯이, 본 방법은 SCD 발생 최대 90분 전까지 정확하게 예측하며 최첨단 성능을 달성했습니다.

본 연구에서는 딥러닝 기법 기반의 새로운 접근법을 제안하여 강력한 급성 심장사(SCD) 탐지 모델을 개발합니다. 효율적인 모델 학습을 위해, 먼저 ECG 신호의 시간-주파수 특징을 1차원 이산 푸리에 변환(DFT)으로 변환하여 전처리하고, 이를 입력 특징으로 사용하여 합성곱 신경망(CNN) 모델을 학습시킵니다. 기존 연구들과 달리, 본 연구에서는 최첨단 베이지안 최적화 알고리즘을 활용하여 최적의 CNN 아키텍처를 탐색합니다. 결과 섹션에서 보여주듯이, 본 접근법은 대부분의 기존 연구들보다 우수한 성능을 보이며, SCD 발생 최대 90분 전까지 정확하게 예측합니다. 요약하자면, 본 연구의 기여는 다음과 같습니다. a. 원시 ECG 신호 대신 신호의 DFT를 학습시켜 데이터 효율성을 높인 1차원 합성곱 신경망 기반의 딥러닝 접근법을 제안합니다.

- b. 본 연구에서 제시하는 접근 방식은 SCD 발생 최대 90분 전까지 예측할 수 있으며, 이는 기존 방식과 동등하거나 더 나은 수준입니다.
최첨단.
- c. 본 연구에서는 수작업으로 추출한 특징과 딥러닝 접근 방식을 모두 활용한 SCA 탐지 관련 최신 문헌 검토 결과를 종합했습니다.

본 논문의 나머지 부분은 다음과 같이 구성됩니다. 2절에서는 SCD 예측에 사용된 다양한 기법 및 머신러닝 알고리즘에 대해 간략하게 설명합니다. 3절과 4절에서는 데이터셋 수집, 신호 처리 및 간격 계산, 1차원 신경망 알고리즘, 실험 설정 등 방법론을 설명합니다. 5절에서는 제안된 방법의 결과 및 비교 분석을 제시합니다.

마지막으로, 6절에서 본 논문의 결론을 제시합니다.

2. 방법론

이전 절에서 논의된 기존 접근 방식과 달리, 본 논문에서 제안하는 접근 방식은 합성곱 신경망(CNN) 기반의 최신 딥러닝 기술을 활용합니다. 본 접근 방식의 장점은 두 가지입니다. i) 수작업으로 특징을 추출하는 기존 방식과 비교하여, 본 접근 방식은 SCD 발병 예측의 기본 패턴을 내재적으로 학습함으로써 엔드투엔드 학습을 제공합니다. ii) 결과 섹션에서 보여주듯이, 본 접근 방식은 SCD 발병을 최대 90분까지 더 정확하게 예측했습니다. 그림 1은 제안된 접근 방식의 개략도를 보여줍니다.

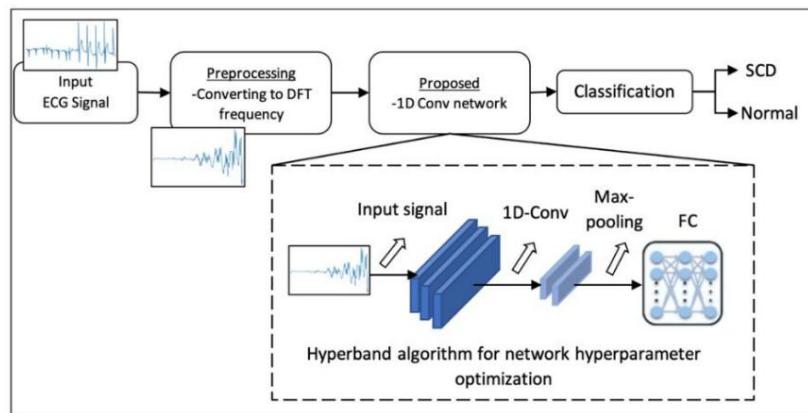


그림 1. 제안된 방법의 개략도

2.1. 데이터셋

제안된 방법은 널리 사용되는 MIT-BIH 부정맥 데이터베이스[33](급성 심장사 훌터 데이터베이스)를 사용하여 평가되었습니다. 이 데이터 세트는 BIH 부정맥 연구실에서 47명의 피험자로부터 수집된 48개의 30분 보행 ECG 신호로 구성된 2채널 데이터셋입니다. 4,000개의 데이터셋 중에서 입원 환자와 외래 환자를 모두 대표하는 24시간 보행 ECG 기록 23개를 무작위로 추출했습니다. 나머지 25개의 기록은 발생 빈도가 낮은 중요한 부정맥을 대표하도록 신중하게 선택했습니다. 이 기록들은 두 명의 독립적인 심장 전문의가 수동으로 주석을 달아 10mV 범위에서 11비트 해상도로 초당 360 개의 샘플 속도로 디지털화된 데이터를 생성했습니다.

2.2. ECG 신호 전처리 및 간격 계산

이산 푸리에 변환(DFT)은 ECG 신호의 주파수 성분에 대한 정확한 정보를 나타냅니다. DFT는 심박수 이상과 관련된 변동을 명확하게 포착 하므로 SCD 예측에 적합합니다. 또한, ECG 신호의 1분 단위 분할 샘플은 장기적인 시간적 변화를 본질적으로 제거합니다. 모든 환자의 ECG 신호는 분류기의 학습 및 테스트를 위해 1분 단위로 분할됩니다. 이러한 1분 단위 청크는 분류기 입력에 대한 해당 DFT 표현으로 변환됩니다. T개의 샘플을 갖는 시간 영역 이산 ECG 청크 $S(t)$ 에 대한 해당 DFT는 $F(w)$ 로 표현될 수 있으며, 여기서 $F(w)$ 는 신호의 ' w ' 주파수 성분의 크기이고 (1)로 주어집니다.

$$(1) = \sum_{w=0}^W F(w) e^{-j2\pi w t} \quad (1)$$

그림 2(a)부터 2(f)에 나타낸 바와 같이 정상 환자의 ECG를 DFT로 전처리합니다. 그림 2(a)와 그림 2(d)는 정상인과 SCD 환자의 ECG 신호의 예를 각각 보여줍니다. 그림 2(b)와 그림 2(e)는 정상인과 SCD 환자의 10초 ECG 샘플 조각을 각각 보여줍니다. 마지막으로,

그림 2(c)와 2(f)는 분류기 학습을 위한 전처리된 DFT 신호를 보여주며, 이는 심박수의 불규칙성과 그 변동을 생생하게 포착합니다.

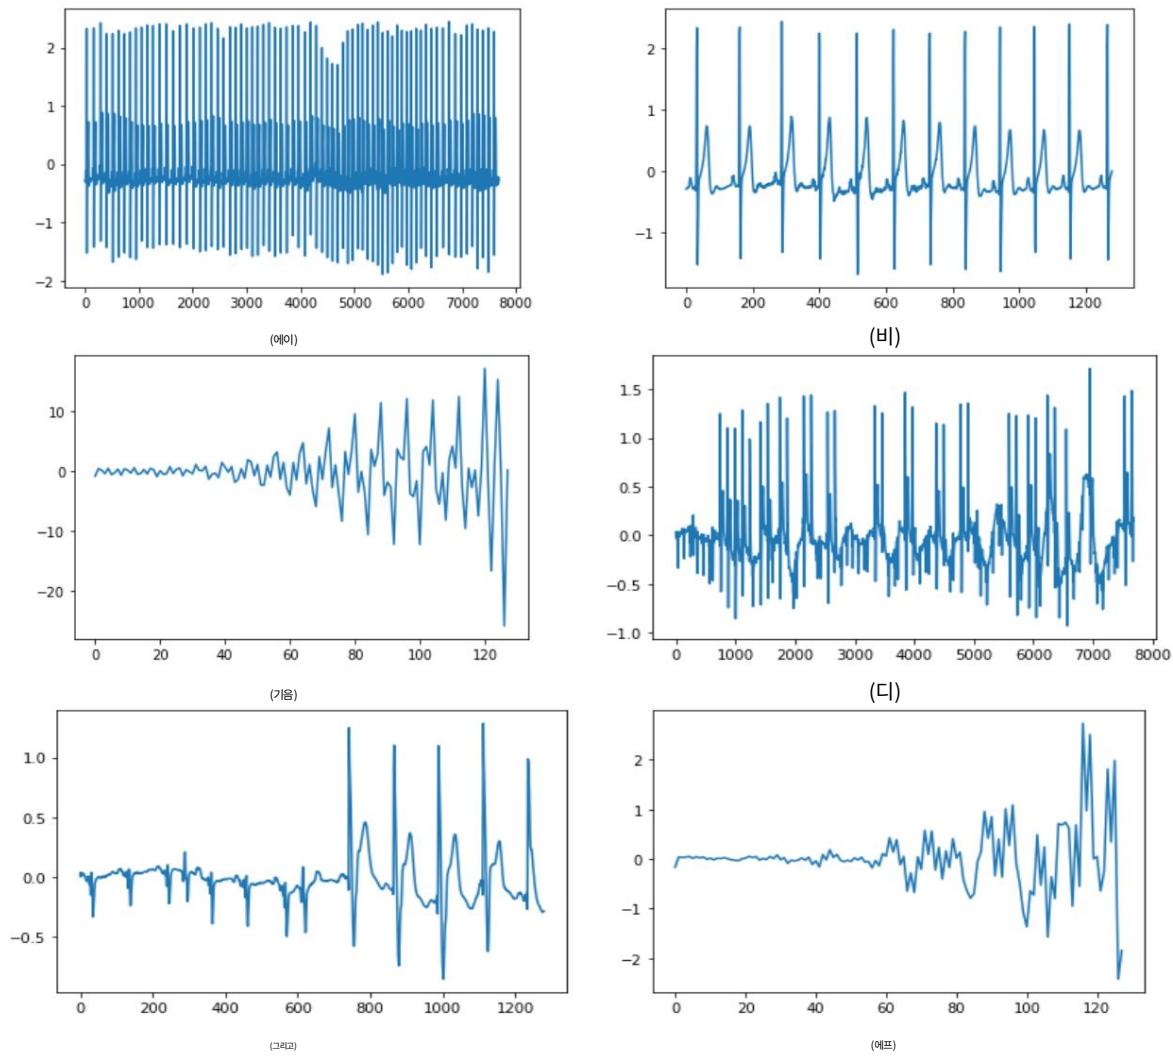


그림 2. 정상 환자의 ECG를 DFT로 전처리하는 과정 (a) 정상 환자의 1분 ECG 샘플, (b) 정상 환자의 10초 ECG 샘플, (c) 정상 환자의 1분 ECG 구간 DFT, (d) SCD 환자의 1분 ECG 샘플, (e) SCD 환자의 10초 ECG 샘플, (f) SCD 환자의 1분 ECG 구간 DFT

2.3. 1차원 합성곱 신경망

제안된 분류기는 1분 ECG 세그먼트 각각에 대해 이산 푸리에 변환(DFT)의 주파수 빈에 걸쳐 컨볼루션을 수행하는 1차원 컨볼루션 신경망을 기반으로 합니다. 이 컨볼루션 네트워크는 입력 신호의 위치에 관계없이 일정하기 때문에 ECG 표현에서 이상 징후를 예측하는데 적합합니다. 또한, 신호를 따라 슬라이딩하는 컨볼루션 필터에 공유되는 파라미터 덕분에 저전력 장치에서도 효율적인 학습이 가능합니다. DFT 표현 $F(w)$ 가 주어지면, 주파수 축, 즉 w 성분을 따라 슬라이딩 윈도우 방식으로 컨볼루션 연산이 적용됩니다.

주파수 축을 가로질러 적용된 컨볼루션 레이어의 출력은 $O(n)$ 으로 표현됩니다(식 (2)에서 볼 수 있듯이 $O(n)$ 은 길이 l 의 커널 필터 $K(i)$ 와의 컨볼루션으로 생성된 출력 벡터의 n 번째 인덱스입니다).

$$(t) = \sum (t)(w + \bar{w}) \quad (2)$$

컨볼루션 레이어의 출력은 분류를 위해 완전 연결 밀집 레이어로 전달됩니다. 신경망 모델의 아키텍처는 하이퍼파라미터 튜닝을 통해 최종적으로 결정되었습니다. 컨볼루션은 DFT와 출력 벡터의 주파수 축을 따라 크기 l 의 작은 윈도우를 슬라이딩하는 것과 같습니다.

이 데이터는 모든 윈도우에 걸쳐 가중치가 공유되는 슬라이딩 윈도우의 가중 평균을 포함합니다. 컨볼루션 레이어의 출력 표현 $O(n)$ 은 평탄화되어 SCD의 가능성을 예측하는 피드포워드 분류기의 입력으로 사용됩니다.

단일 1차원 컨볼루션 레이어는 각각 커널 크기가 8이고 주파수 빈을 8의 스텝 크기로 이동하는 16개의 필터로 구성됩니다. 컨볼루션 레이어에는 배치 정규화와 ReLU 활성화 함수가 포함되며, 그 뒤에 맥스 풀링 기반의 서브샘플링 레이어가 이어집니다. 서브 샘플링 레이어의 출력은 플랫 임베딩으로 재구성된 후 40개의 유닛을 가진 완전 연결 밀집 레이어를 거칩니다. 마지막으로, 밀집 레이어는 목표 범주에 대한 클래스 유사 가능성을 나타내는 두 개의 SoftMax 유닛으로 구성된 출력 레이어에 연결됩니다. 제안된 SCD 예측 알고리즘은 알고리즘 1에 나타나 있습니다.

알고리즘 1. SCD 예측을 위한 제안 알고리즘

입력: ECG 신호(E)

출력: 분당 클래스 레이블(L)

1. 세그먼트 E 를 1분 단위 시간 단위로 분할 S

2. DFT를 이용하여 S 에 대한 F 를 계산합니다: $F(w) = \sum_{t=1}^{T_s} S(t) e^{-j2\pi \frac{wt}{T_s}}$

3. 합성곱을 이용하여 F 에 대한 O 를 계산합니다: $O(n) = \sum_i K(i) F(in + \frac{n}{2})$

4. 피드포워드 분류기를 사용하여 O 에 대한 클래스 가능성 K 를 계산합니다.

5. 클래스 레이블 $L = \text{argmax}(K)$ 를 계산합니다.

6. L 을 반환하세요

3. 실험 장치 구성

정상인과 SCD 환자 모두의 ECG 데이터는 2채널 신호로 구성됩니다. 실험에서는 두 환자 유형 모두에서 첫 번째 채널만 고려했습니다. 정상인 18명의 ECG 데이터는 모두 사용되었고, SCD 환자의 경우 심실세동(VF) 발생 시점 정보가 없는 3명을 제외하고 20명의 ECG 데이터만 사용했습니다. 데이터 세트에서 정상인의 ECG 신호는 초당 128개의 샘플링 속도로, SCD 환자의 ECG 신호는 초당 250개의 샘플링 속도로 샘플링되었습니다. 정상인과의 편향 없는 비교를 위해 SCD 환자의 ECG 신호는 초당 128개의 샘플링 속도로 다운샘플링했습니다. 분류 모델은 10분 분량의 ECG 신호를 사용하여 학습되었습니다. SCD 환자의 경우 VF 발생 전 10분을 학습 데이터로 선택했고, 정상인의 경우 임의의 10분을 학습 데이터로 선택했습니다.

10분간의 훈련 데이터는 1분 단위로 분할되어 훈련 샘플로 사용되며, 각 샘플에는 환자의 유형(SCD 또는 정상)을 나타내는 레이블이 지정됩니다. 각 1분 길이의 ECG 신호 샘플은 1024개의 주파수 빈 해상도를 갖는 이산 푸리에 변환(DFT)으로 변환됩니다. 1분 단위 세그먼트의 DFT 표현은 CNN 기반 분류 모델의 입력 특징으로 사용됩니다. 분류 모델의 훈련 및 테스트는 서로 다른 환자들의 ECG 신호를 사용하여 수행됩니다.

본 분류 모델은 1분 길이의 심전도(ECG) 구간에 대한 이산 푸리에 변환(DFT)과 주파수 대역별 컨볼루션을 적용한 CNN을 입력 특징으로 사용합니다. DFT 외에도 이산 웨이블릿 변환(DWT), 시간-주파수 스펙트로그램, 그리고 원시 ECG 신호를 분류 모델의 입력으로 테스트한 결과, DFT가 가장 우수한 성능을 보였습니다. CNN 학습에는 18명의 환자 데이터셋(급성 심장사 환자 10명, 정상 환자 8명)을 사용했으며, 테스트에는 각 데이터셋에서 10명씩 총 20명의 환자 데이터를 사용했습니다.

훈련 데이터셋을 테스트 데이터셋보다 작게 유지하는 것은 실제 문제에서 나타나는 레이블이 지정된 ECG 데이터셋의 제한된 크기를 모사하는 것입니다. 훈련 및 테스트 주기는 10회 반복되었으며, 각 반복마다 다른 환자를 샘플링했습니다. 훈련된 모델은 테스트 환자의 경우 1분 단위로 테스트되었는데, SCD 환자의 경우 SCD 발생 5분 전부터 최대 90 분까지를 테스트 구간으로 선택했고, 정상 환자의 경우 무작위로 샘플링된 구간을 테스트 구간으로 선택했습니다.

4. 결과 및 논의

본 섹션에서는 예측 작업을 위해 다양한 입력 특징과 분류 모델을 분석하고 그 결과를 요약했습니다. 그림 3은 1024개의 빈으로 나뉜 DFT 주파수를 입력으로 사용하여 20명의 테스트 환자에 대한 CNN 모델의 예측 정확도를 보여줍니다. 예측 정확도는 서로 다른 훈련 및 테스트 샘플을 10회 반복하여 평균값을 구했습니다. 결과에 따르면, SCD 발생 90분 전까지 예측 정확도가 94% 이상을 유지했습니다. 모델은 SCD 발생 15분 전에 99.5%의 최고 정확도를 달성했습니다. SCD 발생 5분 전과 10분 전의 예측 정확도는 각각 98.5%와 97.5%였습니다.

SCD에 가까운 몇 분, 특히 15분 전까지의 시간에서 정확도가 높게 나타납니다. 15분 이후에는 정확도가 서서히 떨어지지만, 90분 동안 92.5%에서 99.5% 사이에서 선형적인 추세 없이 변동합니다. 정확도는 5분 간격으로 측정되었습니다.

DFT를 최종 입력으로 사용하기 전에, 여러 특징들을 CNN 모델의 입력으로 테스트했습니다. SCD 발생 60분 전 데이터를 분석하여 모든 특징을 검증했으며, 표 1은 서로 다른 환자를 대상으로 10회 반복 실험한 평균 정확도를 보여줍니다. DFT는 DWT, Raw, 스펙트로그램과 같은 다른 특징들보다 우수한 성능을 보였으며, 94.5%의 정확도를 나타냈습니다.

DFT 특징 외에도 원시 ECG 신호, 이산 웨이블릿 변환(DWT), 이산 푸리에 변환(DFT), 시간-주파수 스펙트로그램 등의 특징을 비교했습니다. 표 1에서 DFT가 가장 높은 정확도를 보였으며, 스펙트로그램 또한 DWT 및 원시 ECG에 비해 상대적으로 높은 90%의 정확도를 나타냈습니다. DWT에는 DB4를 모 웨이블릿으로 사용했습니다. DFT를 입력 표현으로 최종 결정한 후, DFT에 적합한 주파수 빈 개수를 선택하기 위해 경험적 분석을 수행했습니다. 동일한 CNN 아키텍처를 사용하여 서로 다른 DFT 주파수 길이로 SCD 발생 60분 전을 예측했습니다. 또한 표 2에서는 SCD 발생 60분 전의 '민감도'와 '특이도'를 계산했습니다. '민감도'는 특히 SCD 양성 예측에 대한 정확한 분류율을 나타내고, '특이도'는 SCD 음성 예측 또는 정상 예측에 대한 정확한 분류율을 나타냅니다.

이 모델은 민감도 95.5%, 특이도 93.5%를 나타냈는데, 이는 정상 환자를 정확하게 예측하는 것보다 SCD에 취약한 환자를 예측하는 데 약간 더 정확하다는 것을 의미합니다. 주파수 빈 선택의 영향을 분석한 결과(그림 4 참조)는 흥미로운 패턴을 보여줍니다. 결과는 DFT의 주파수 해상도가 높을수록 예측 정확도가 1024개 주파수 빈까지 단조롭게 증가하다가 그 이후에는 60번째 모델에서 94.5%의 안정적인 수준에 도달함을 확인시켜 줍니다.

또한 제안된 모델의 성능을 다른 아키텍처와 비교했습니다. 그림 5는 이를 보여줍니다. 다른 모델들과의 성능 차이를 살펴보면, 우리 모델이 다른 모든 모델들에 비해 상당히 우수한 성능을 보였음을 분명히 알 수 있습니다. 이는 CNN 모델에 사용된 DFT 특징이 다른 모델들보다 SCD 발병을 더 정확하게 예측할 수 있음을 시사합니다.

4.2. 최첨단 기술과의 성능 비교

본 연구에서는 제안된 방법론을 기준 최첨단 방법들과 비교했습니다. 사용된 데이터셋, 신호 길이, 특징 추출 방법 및 특징 개수, 분류기, 성능 지표(정확도, 민감도, 특이도) 등 다양한 측면에서 최근 연구들과 비교 분석을 진행했습니다. 표 3에서 볼 수 있듯이, 제안된 방법은 피질 확산 탈분극(CSD) 발병 전 60분 동안의 추가 신호에 대해 정확도를 유지하면서 대부분의 최첨단 방법들보다 우수한 성능을 보였습니다. 특히, 본 연구에서는 종종 복합 면역결핍증(SCID) 발병 전 50분의 신호 길이를 사용하여 DFT(1024) 분류기로 97%의 정확도, 97.5%의 민감도, 96.5%의 특이도를 달성했습니다.

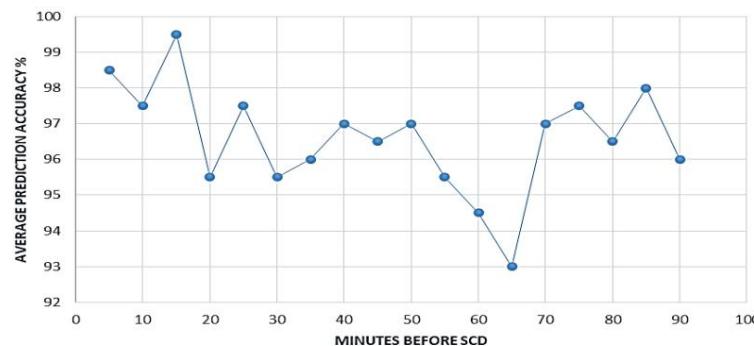


그림 3. SCD 발생 전 몇 분에 대한 예측 정확도(%)

표 1. DFT와 다른 특징들의 성능 비교

특징	평균 정확도 %
DWT	52.5
원재료	54.0
DFT	94.5
스펙트로그램	90.0

표 2. DFT에 대한 SCD 예측 점수

특징	정확도 %	민감도 %	특이도 %
디프티	94.5	95.5	93.5

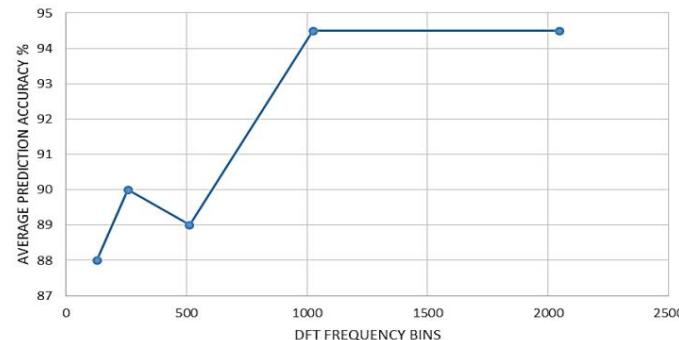


그림 4. 서로 다른 빈 크기 빈도를 사용했을 때의 성능 비교

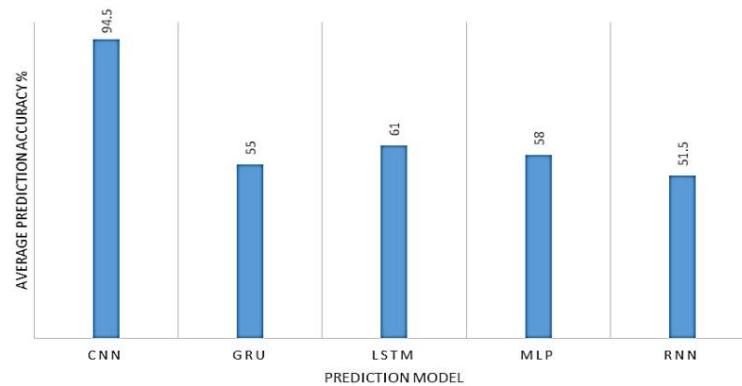


그림 5. CNN과 다른 모델들의 성능 비교

표 1. 본 알고리즘과 최근 개발된 다른 심장 돌연사 예측 방법들의 비교
심전도 매개변수 및 심박 변이도 신호를 기반으로

저자 (연도)	데이터 유형	데이터셋 사용됨	신호 길이(분)	특징 추출 (기능 개수)	방법론	분류기	정확도 (%)	최고의 성능 그들은 (%)	Spe (%)
아차 라 등 (2015) [25]	ECG SDDB	NSRDB	4분	비선형 특징(18) 및 SCIDI	DT, SVM	92.11% 92.50%		91.67%	
후지타 등 (2016) [26]	HRV SDDB	NSRDB	4분	비선형 특징	SVM, KNN	94.70% 95.00%		94.40%	
산체스 외 (2018) [24]	ECG SDDB	NSRDB	SCID 20분 전	비선형 심박수 변동성 분석	EPNN	95.80% 알 수 없음	알 수 없음		
카자이 등 (2018) [23]	HRV SDDB	NSRDB	SCID 6분 전	비선형 방법 안녕 웨이브 패킷 변환 RQA(13) 및 증가 엔트로피(14 개 중 2개)	DT, KNN, SVM, NB	95.00% 95.00%		95.00%	
Ebrahimzadeh et al. (2018) [22]	HRV SDDB	NSRDB	SCID 12분 전	비선형 방법 HRV 특징(23) 시간 로컬 부분집합 특징 선택	MLP	88.29% 알 수 없음	알 수 없음		
Ebrahimzadeh et al. (2019) [7]	HRV SDDB	NSRDB	SCID 13분 전	HRV 특징(23) 시간 로컬 부 분집합 특징 선택	MLP	90.18% 알 수 없음	알 수 없음		
Lai et al. (2019) [21]	ECG SDDB	NSRDB AHADB	SCID 30분 전	부정맥 위험 지표(5) 및 SCDI	DT, KNN, SVM, NB, RF	99.49% 99.75%		99.04%	
본 연구는 ECG SDDB를 사용합니다.	NSRDB		SCID 30분 전	DFT(1024)	CNN	95.50% 97.00%		94.00%	
본 연구는 ECG SDDB를 사용합니다.	NSRDB		SCID 50분 전	DFT(1024)	CNN	97.00% 97.50%		96.50%	
본 연구는 ECG SDDB를 사용합니다.	NSRDB		SCID 60분 전	DFT(1024)	CNN	94.50% 95.50%		93.50%	

5. 결론

본 연구에서는 딥러닝 기법을 이용하여 급성 심장사(SCD)를 예측하는 문제를 탐구했습니다. 최근 연구에서 주로 사용되는 특징 엔지니어링 기법에도 불구하고, 장시간에 걸쳐 정확한 예측을 위해서는 효율적인 학습 알고리즘이 필수적임을 확인했습니다. 따라서, 환자의 심전도(ECG) 신호에서 추출한 이산 푸리에 변환(DFT) 특징의 기본 패턴을 자동으로 학습하는 딥러닝 기법을 제안했습니다. 제안된 방법은 추가적인 계산량 증가는 최소화하면서 장시간에 걸쳐 정확한 예측을 달성하여 최첨단 성능을 보였습니다. 또한, 기존 딥러닝 모델(LSTM, GRU, MLP, RNN 등)과의 비교를 통해 제안된 방법이 기존 모델보다 훨씬 우수한 성능을 나타냄을 확인했습니다. 향후 연구에서는 차원 축소 기법을 적용하여 현재 제안된 방법의 추가적인 계산량 증가 문제를 해결하고자 합니다. 또한, 네트워크 가중치 가지치기를 통해 저사양 기기에서도 모델 성능을 유지하면서 대규모 모델의 크기를 줄이는 방안을 모색할 계획입니다.

참고문헌

- [1] S. Sahoo, M. Dash, S. Behera 및 S. Sabut, "ECG 신호에서 심장 부정맥을 감지하기 위한 기계 학습 접근법: 설문 조사", IRBM, 41권, 4호, 185-194쪽, 2020년 8월, doi: 10.1016/j.irbm.2019.12.001.
- [2] UR Acharya et al., "심장 박동을 분류하기 위한 심증 합성 신경망 모델," 생물학 및 의학 분야 컴퓨터, 제89권, 389-396쪽, 2017년 10월, doi: 10.1016/j.combiomed.2017.08.022.
- [3] A. Beri 및 K. Kotak, "COVID-19 환자의 심장 손상, 부정맥 및 급사", HeartRhythm Case Reports, vol. 6, no. 7, pp. 367-369, 2020년 7월, doi: 10.1016/j.hrcr.2020.05.001.
- [4] http://dx.doi.org/10.1037/0021-843X.103.2.201 S. Babapoor-Farrokhyan, R. Rasekh, D. Gill, S. Babapoor, A. Amanullah, "COVID-19의 부정맥," SN Comprehensive Clinical Medicine, vol. 2, 아니. 9, pp. 101-1 1430-1435, 2020년 8월, doi: 10.1007/s42399-020-00454-2
- [5] A. Carpenter et al., "COVID-19 관리 및 부정맥: SARS-CoV-2에 영향을 받는 환자를 치료하는 임상의를 위한 위험 및 과제," Frontiers in Cardiovascular Medicine, vol. 7, 2020년 5월, doi: 10.3389/fcvm.2020.00085.
- [6] EBM Tamil, NH Kamardin, R. Salleh 및 AM Tamil, "생체 신호 처리를 위한 특징 추출 및 분류 기술에 대한 검토(파트 I: 심전도)", 제 4회 쿠알라룸푸르 국제 생의학 공학 컨퍼런스 2008, 2008, pp. 107-112. doi: 10.1007/978-3-540-69139-6_31.
- [7] E. Ebrahimzadeh 외, "HRV 신호에서 선구적인 특징 선택 접근 방식을 통한 급성 심장사 예측을 위한 최적 전략", 컴퓨터 방법 및 생의학 프로그램, 169권, 19-36쪽, 2019년 2월, doi: 10.1016/j.cmpb.2018.12.001.
- [8] PW Armstrong, JT Willerson, 및 DM Roden, "임상 심장학: 새로운 지평", Circulation, 제97권, 제12호, 1107쪽-1107, 1998년 3월, doi: 10.1161/01.cir.97.12.1107.
- [9] SS Yadav 및 SM Jadhav, "기계 학습 알고리즘을 이용한 심장 부정맥 진단을 위한 공동 위험 요인 탐지", Expert Systems with Applications, vol. 163, p. 113807, 2021년 1월, doi: 10.1016/j.eswa.2020.113807.
- [10] M. Alfaras, MC Soriano 및 S. Ortín, "ECG 기반 심장 박동 분류를 위한 빠른 기계 학습 모델 및 부정맥 감지," Frontiers in Physics, vol. 7, 2019년 7월, doi: 10.3389/fphy.2019.00103.
- [11] M. Murugappan, L. Murugesan, S. Jerritta 및 H. Adeli, "ECG 형태학적 특징을 이용한 급성 심정지(SCA) 예측", Arabian Journal for Science and Engineering, vol. 46, no. 2, pp. 947-961, 2020년 7월, doi: 10.1007/s13369-020-04765-3.
- [12] KV Reddy 및 N. Kumar, "심전도 신호에서 통계적으로 추출한 특징을 이용한 급성 심장사 자동 예측", International Journal of Electrical and Computer Engineering (IJECE), vol. 12, no. 5, pp. 4960-4969, 2022년 10월, doi: 10.11591/ijece.v12i5.pp4960-4969.
- [13] VVR Karna, S. Paramasivam, I. Elamvazuthi, HN Chua, AA Aziz 및 P. Satyamurthy, "최적화된 머신러닝을 이용한 심장질환 위험 예측을 위한 새로운 특징 엔지니어링", 2022년 스마트 커뮤니티의 미래 동향에 관한 국제 컨퍼런스(ICFTSC), 2022년 12월, 158-163쪽. doi: 10.1109/icftsc57269.2022.10040063.
- [14] BH Priya, C. Chaitra 및 KV Reddy, "질병 예측을 위한 기계 학습 알고리즘의 성능 분석", 2021 Grace Hopper Celebration India(GHCI), 2021년 2월, 1-6쪽. doi: 10.1109/ghci50508.2021.9514000.
- [15] A. Mohammed Shanshool, EM Hussien Saeed 및 H. Hadi Khaleel, "인간 심장학의 조기 진단을 위한 다양한 데이터 마이닝 방법 비교," IAES International Journal of Artificial Intelligence (IJ-AI), vol. 12, no. 3, pp. 1343-1351, 2023년 9월, doi: 10.11591/ejai.v12.i3.pp1343-1351.
- [16] AH Ribeiro et al., "심층 신경망을 이용한 12리드 ECG의 자동 진단," Nature Communications, vol. 11, no. 2020년 4월 1일, doi: 10.1038/s41467-020-15432-4.
- [17] KS Nugroho, AY Sukmadewa, A. Vidianto 및 WF Mahmudy, "지원 벡터 머신을 사용한 관상동맥 질환에 대한 효과적인 예측 모델링," IAES International Journal of Artificial Intelligence (IJ-AI), vol. 11, no. 1, pp. 345-355, 2022년 3월, doi: 10.11591/ijai.v11.i1.pp345-355.
- [18] KV Reddy 및 N. Kumar, "운전자의 다양한 상태를 감지하기 위한 EEG 신호의 웨이블릿 기반 분석", 2019년 국제 통신 및 신호 처리 컨퍼런스(ICCSP), 2019년 4월, 0616-0620쪽. doi: 10.1109/iccsp.2019.8697902.
- [19] J. Liu, S. Song, G. Sun 및 Y. Fu, "CNN, SVM 및 LDA를 사용한 ECG 부정맥 분류", 인공지능 및 보안, Springer International Publishing, 2019, pp. 191-201. doi: 10.1007/978-3-030-24265-7_17.
- [20] KVV Reddy, I. Elamvazuthi, AA Aziz, S. Paramasivam, HN Chua 및 S. Pranavanand, "심혈관 질환 위험 예측 정확도 향상을 위한 회전 포레스트 양상을 분류기", 2021년 12월 8회 NAFOSTED 정보 및 컴퓨터 과학 컨퍼런스(NICS), 404-409쪽. doi: 10.1109/nics54270.2021.9701455.
- [21] D. Lai, Y. Zhang, X. Zhang, Y. Su 및 MB Bin Heyat, "측정 가능한 부정맥 위험 지표에 대한 기계 학습 접근법을 이용한 급성 심장사 조기 위험 식별 자동화 전략", IEEE Access, vol. 7, pp. 94701-94716, 2019, doi: 10.1109/access.2019.2925847.
- [22] E. Ebrahimzadeh, MS Manuchehri, S. Amoozegar, BN Araabi 및 H. Soltanian-Zadeh, "ECG 신호에서 급성 심장사 예측을 위한 시간 로컬 부분 집합 특징 선택", Medical & Biological Engineering & Computing, vol. 56, no. 7, pp. 1253-1270, 2017년 12월, doi: 10.1007/s11517-017-1764-1.

- [23] M. Khazaei, K. Raeisi, A. Goshvarpour 및 M. Ahmadzadeh, "심박수 변동성의 비선형 분석을 이용한 급성 심장사 조기 발견", *Biocybernetics and Biomedical Engineering*, vol. 38, no. 4, pp. 931-940, 2018, doi: 10.1016/j.bbe.2018.06.003.
- [24] JP Amezquita-Sanchez, M. Valtierra-Rodriguez, H. Adeli 및 CA Perez-Ramirez, "ECG 신호를 사용한 급성 심장사 예측을 위한 새로운 웨이블릿 변환-균질성 모델", *Journal of Medical Systems*, vol. 42, no. 10, 2018년 8월, doi: 10.1007/s10916-018-1031-5.
- [25] UR Acharya et al., "이산 웨이블릿 변환 및 비선형 특성을 이용한 급성 심장사 감지를 위한 통합 지수," *지식 기반 시스템*, 83권, 149-158쪽, 2015년 7월, doi: 10.1016/j.knosys.2015.03.015.
- [26] H. Fujita 등, "비선형 심박수 변동 특성 및 SCD 지수를 기반으로 한 급성 심장사(SCD) 예측" *응용 소프트 컴퓨팅*, 제43권, 510-519쪽, 2016년 6월, doi: 10.1016/j.asoc.2016.02.049.
- [27] J. Kwon, Y. Lee, Y. Lee, S. Lee 및 J. Park, "병원 내 심정지 예측을 위한 딥러닝 기반 알고리즘" *미국심장협회지널*, 제7권, 제13호, 2018년 7월, doi: 10.1161/jaha.118.008678.
- [28] A. Elola et al., "병원 밖 심정지 중 ECG 기반 맥박 감지를 위한 심층 신경망," *Entropy*, vol. 21, 제3호, 305쪽, 2019년 3월, doi: 10.3390/e21030305.
- [29] MT Nguyen, B. Van Nguyen 및 K. Kim, "자동 외부 제세동기에서 급성 심정지 감지를 위한 심층 특징 학습", *Scientific Reports*, vol. 8, no. 1, 2018년 11월, doi: 10.1038/s41598-018-33424-9.
- [30] S. Tonekaboni et al., "소아 중환자실에서 생리적 신호를 이용한 심정지 예측," *기계공학 학술대회 논문집 학습 연구*, 제85권, 534-550쪽, 2018년.
- [31] Y. Lee, J. Kwon, Y. Lee, H. Park, H. Cho 및 J. Park, "의료 영역의 딥 러닝: 딥 러닝을 이용한 심정지 예측", *급성 및 중환자 치료*, 33권, 3호, 117-120쪽, 2018년 8월, doi: 10.4266/acc.2018.00290.
- [32] J. Kim, M. Chae, H.-J. Chang, Y.-A. Kim 및 E. Park, "환자 데이터의 간단한 궤적을 이용한 실현 가능한 인공지능을 사용하여 심정지 및 호흡 부전 예측", *임상 의학 저널*, 8권, 9호, 1336쪽, 2019년 8월, doi: 10.3390/jcm8091336.
- [33] GB Moody 및 RG Mark, "MIT-BIH 부정맥 데이터베이스의 영향", *IEEE 의학 및 생물학 공학 잡지*, 제20권, 제3호, 45-50쪽, 2001년, doi: 10.1109/51.932724.

작가 약력



JNTU에서 비스와바르단 레디 카르나 2008년 인도 안드라프라데시 주 하이데라바드에 위치한 전자통신공학 학사 학위를, 2011년 스웨덴 칼스코로나에 위치한 블레킹에 공과대학교에서 통신 시스템 석사 학위를 취득했습니다. 이후 2023년 인도 벵갈루루에 위치한 자인 대학교에서 전자공학 박사 학위를 받았습니다. 현재 인도 벵갈루루에 있는 RV 공과대학 전자통신공학과에서 조교수로 재직하고 있습니다.

그의 연구 분야는 기계 학습, 인공지능, 무선 신체 영역 네트워크, 무선 센서 네트워크 및 소프트웨어 정의 네트워크를 포함합니다. 이메일 주소는 viswvardhank@rvce.edu.in입니다.



카르나 비슈누 바르다나 레다는 2004년 인도 하이데라바드의 자와হ랄 네루 공과대학교에서 전자통신공학 학사 학위를 취득했습니다. 이후 2006년 인도 아난타푸르의 스리 크리슈나데바라야 대학교에서 통신 및 신호처리 석사 학위를 받았습니다.

2023년 말레이시아 페트로나스 공과대학교(Universiti Teknologi PETRONAS)에서 전기전자공학 박사 학위를 취득했습니다. 2006년부터 2013년까지 인도 여주 대학에서 조교수로, 2013년부터 2021년까지 말레이시아에서 선임 강사로 재직했습니다. 현재는 인도 수란팔렘에 위치한 아디티야 공과대학(Aditya Engineering College (A)) 전자통신공학과 부교수로 재직 중입니다. 총 16년의 교육 및 연구 경력을 보유하고 있으며, 재직 기간 동안 다수의 통합 설계 프로젝트와 졸업 프로젝트를 지도했습니다. 인도공학회(IET), 전기전자공학회(IEEE), 영국공학기술협회(IET)의 회원입니다. 이메일 주소는 vishnuvardhanreddyk@aec.edu.in입니다.